

Lições Aprendidas

Mudança de perspectiva do NRPP com a incorporação da ISDF

Este documento registra as principais lições aprendidas na evolução do Normative-to-Record Preprocessing Pipeline (NRPP), especialmente na passagem de uma abordagem centrada na identificação de evidências documentais para uma abordagem orientada pela Norma Internacional para Descrição de Funções (ISDF).

O objetivo é explicitar o que mudou, o que permaneceu válido e quais cuidados devem orientar as próximas evoluções metodológicas e técnicas do pipeline.

1. Perspectiva original

Na primeira versão operacional, o NRPP foi concebido como um pipeline de apoio à extração estruturada de informações a partir de normativos institucionais.

A preocupação principal era identificar, nos textos normativos:

- documentos explicitamente mencionados;
- artefatos informacionais requeridos;
- ações normativas que sugerissem produção, uso ou guarda de registros;
- segmentos textuais relevantes para posterior validação humana.

Essa abordagem era adequada para iniciar a organização de evidências documentais, pois reduzia a complexidade dos normativos e produzia uma planilha de validação baseada em trechos rastreáveis.

Entretanto, a perspectiva original ainda tratava os documentos como o principal ponto de chegada da análise. A função institucional aparecia de forma indireta, como contexto do documento ou do processo.

2. Limite identificado

A leitura orientada apenas por documentos revelou um limite metodológico importante: a produção documental não pode ser compreendida de forma suficiente quando separada das funções institucionais que a originam.

Nos normativos da CAIXA, muitos registros não aparecem apenas como documentos isolados. Eles estão associados a:

- responsabilidades de unidades organizacionais;
- competências formais;
- atividades e tarefas;
- procedimentos de controle;
- bases legais;
- sistemas de informação;

- relações entre áreas, processos e recursos arquivísticos.

Assim, uma evidência documental extraída automaticamente só ganha significado arquivístico mais robusto quando situada no contexto funcional que explica sua produção, uso e manutenção.

3. Contribuição da ISDF

A ISDF desloca o foco metodológico para a descrição de funções de entidades coletivas associadas à produção e manutenção de arquivos.

Essa mudança é relevante para o NRPP porque permite organizar as evidências extraídas dos normativos em torno de elementos como:

- tipo funcional: função, subfunção, atividade, tarefa ou transação;
- forma de descrição da função;
- datas e períodos de vigência;
- base legal;
- relacionamentos entre funções;
- relacionamentos entre funções, entidades coletivas e recursos arquivísticos;
- controle da descrição produzida.

Com isso, o NRPP deixa de ser apenas um pre-processador de documentos citados e passa a ser um instrumento de preparação de descrições funcionais validáveis.

4. Comparação entre as duas abordagens

Aspecto	Perspectiva original	Perspectiva com ISDF
Foco principal	Evidências documentais em normativos	Funções institucionais e seus relacionamentos
Pergunta orientadora	Que documentos ou artefatos aparecem na norma?	Que função, atividade ou responsabilidade explica a produção e manutenção desses documentos?
Produto esperado	Planilha de evidências para validação	Planilha de validação com abas de descrição funcional ISDF
Papel do glossário	Normalizar termos documentais	Apoiar a normalização terminológica dentro de uma estrutura descritiva
Papel da validação humana	Confirmar evidências extraídas	Validar evidências, relações funcionais e enquadramento ISDF
Limite principal	Risco de tratar documento fora do contexto funcional	Requer maior cuidado interpretativo e validação especializada

4.1 Comparação empírica com o PDF AD020122

Para tornar a diferença entre as versões mais visível, foi executado um teste comparativo com o arquivo AD020122.pdf.

A versão v1 corresponde ao estado do NRPP antes da incorporação da ISDF. A versão v2 corresponde ao NRPP com detecção ampliada no A3, enriquecimento ISDF no A4 e novas abas de validação no A5.

Critério observado	NRPP v1	NRPP v2 orientado pela ISDF	Leitura da diferença
Segmentos textuais A2	684	684	A segmentação estrutural permaneceu estável; a mudança ocorreu nas etapas semânticas e de estruturação.
Evidências semânticas A3	350	663	A v2 ampliou a detecção de pistas, incluindo função, entidade coletiva, legislação, datas e relacionamentos.
Classes detectadas no A3	documento; processo	documento; processo; função; entidade coletiva; legislação; data; relacionamento	A v1 separava basicamente documentos e processos; a v2 aproxima a leitura do modelo funcional da ISDF.

Critério observado	NRPP v1	NRPP v2 orientado pela ISDF	Leitura da diferença
Linhas preservadas no A4	28	663	A v1 mantinha apenas evidências normalizadas pelo glossário; a v2 preserva todas as evidências e marca o que exige validação.
Termos normalizados por glossário	28	60	A v2 aumentou a cobertura terminológica, mas seu principal ganho é preservar também evidências ainda não normalizadas.
Evidências classificadas com elemento ISDF	não aplicável	663	Todas as evidências da v2 recebem enquadramento preliminar em área ou elemento ISDF.
Itens marcados como <code>necessita_validacao</code>	não aplicável	603	A v2 explicita o que precisa de revisão humana, reduzindo o risco de falsa decisão automática.

Critério observado	NRPP v1	NRPP v2 orientado pela ISDF	Leitura da diferença
Linhas na aba validacao_nrpp	28	408	A planilha final deixa de ser um recorte restrito aos termos normalizados e passa a apoiar revisão funcional mais ampla.
Abas do Excel final	5	8	A v2 acrescenta descricao_isdf , relacionamentos_isdf e controle_descricao .
Cópia do PDF original no dossiê	sim	não	A v2 elimina a pasta ENTRADA/ , evitando duplicação desnecessária do PDF original.

Distribuição das classes detectadas no A3 para o arquivo **AD020122.pdf**:

Classe	NRPP v1	NRPP v2 orientado pela ISDF
processo	248	272
documento	102	219
entidade coletiva	0	71
legislação	0	41
relacionamento	0	34
função	0	13
data	0	13

Essa comparação mostra que a v2 não é apenas uma versão com mais colunas. Ela altera a finalidade do produto: a saída deixa de ser uma lista reduzida de documentos normalizados e passa a ser uma matriz de evidências para validação funcional e arquivística.

5. O que permaneceu válido

A mudança de perspectiva não invalida a versão inicial do NRPP. Ao contrário, vários princípios continuam corretos:

- preservação do texto de origem e dos segmentos normativos;
- separação entre processamento automatizado e decisão arquivística;
- rastreabilidade entre evidência extraída e trecho normativo;
- geração de artefatos intermediários auditáveis;
- necessidade de validação humana;
- uso de glossários e vocabulários controlados;
- execução reproduzível em ambiente local.

A principal mudança está na interpretação do produto final. Antes, a planilha era vista como um inventário preliminar de evidências documentais. Agora, ela deve ser vista como uma base de apoio para descrição funcional e análise arquivística orientada pela ISDF.

6. Aprendizados técnicos

A evolução do pipeline mostrou que uma única etapa não deve concentrar toda a inteligência metodológica.

O desenho mais adequado é distribuir responsabilidades:

- A1 extrai e normaliza o texto;
- A2 segmenta a estrutura normativa;
- A3 detecta pistas semânticas;
- A4 normaliza termos e acrescenta metadados ISDF;
- A5 consolida resultados em planilhas de validação humana.

Essa separação permite evoluir cada etapa sem comprometer o conjunto. Também facilita auditoria, testes e manutenção.

7. Aprendizados sobre o A4

A ideia inicial era melhorar o A4 com as diretrizes da ISDF. A conclusão foi que isso é correto, desde que o A4 não seja transformado em uma etapa decisória.

O A4 deve:

- normalizar termos detectados pelo A3;
- consultar glossários e diretrizes estruturadas;
- atribuir campos ISDF preliminares;
- indicar itens que exigem validação;
- produzir uma trilha de auditoria para termos fora do glossário.

O A4 não deve:

- declarar de forma definitiva que uma função está descrita corretamente;
- substituir a análise arquivística;

- inferir sozinho relações institucionais complexas;
- decidir classificação, temporalidade ou destinação documental.

8. Aprendizados sobre o produto final

O produto final não deve ser uma única tabela plana. A incorporação da ISDF exige uma saída mais rica, com abas separadas para diferentes necessidades de revisão.

A estrutura atual do Excel final é mais adequada porque inclui:

- **validacao_nrpp**: visão consolidada para revisão humana;
- **evidencias_normalizadas**: saída completa do A4;
- **descricao_isdf**: agrupamento dos elementos ISDF detectados;
- **relacionamentos_isdf**: relações entre documentos, entidades coletivas e funções;
- **controle_descricao**: campos de controle inspirados na área de controle da ISDF;
- **evidencias_semanticas**: saída do A3;
- **segmentos_texto**: saída do A2;
- **termos_fora_do_glossario**: trilha de auditoria terminológica.

9. Risco de falsa precisão

Um dos principais riscos da nova abordagem é a aparência de precisão excessiva. Como a ISDF possui uma estrutura normativa formal, há risco de o usuário interpretar campos preenchidos automaticamente como descrições arquivísticas finalizadas.

Para mitigar esse risco, o NRPP deve manter linguagem clara de apoio à validação:

- resultados são preliminares;
- campos ISDF são sugestões estruturadas;
- itens marcados como **necessita_validacao** exigem revisão humana;
- decisões arquivísticas permanecem sob responsabilidade profissional.

10. Importância da rastreabilidade

A incorporação da ISDF aumenta a necessidade de rastreabilidade. Cada classificação ou sugestão deve permanecer vinculada ao trecho normativo que a originou.

Isso é essencial porque a validação humana precisa responder a perguntas como:

- qual trecho normativo sustenta esta evidência?
- qual termo foi detectado automaticamente?
- qual classe foi atribuída?
- qual elemento ISDF foi sugerido?

- o termo foi normalizado por glossário ou apenas transportado para validação?

Sem essa rastreabilidade, a automação se torna pouco confiável para uso institucional.

11. Impacto sobre a validação humana

A validação humana deixa de ser apenas uma revisão de documentos detectados e passa a incluir verificação funcional.

O validador deve observar:

- se o trecho realmente descreve uma função, atividade, tarefa ou transação;
- se a entidade coletiva detectada é pertinente;
- se a relação entre função e documento está corretamente caracterizada;
- se há base legal ou temporalidade funcional associada;
- se o termo detectado deve ser incorporado ao glossário;
- se a descrição precisa de complementação manual.

12. Implicações para governança arquivística

A nova perspectiva aproxima o NRPP de uma função institucional mais ampla: apoiar a compreensão da proveniência documental.

Ao relacionar documentos a funções e entidades coletivas, o pipeline passa a produzir insumos mais relevantes para:

- descrição arquivística;
- análise de proveniência;
- entendimento de responsabilidades institucionais;
- mapeamento de registros produzidos por atividades;
- preparação de instrumentos de controle e validação documental.

13. Cuidados para próximas evoluções

As próximas melhorias devem priorizar qualidade metodológica, não apenas aumento de detecções.

Recomendações:

- ampliar gradualmente o arquivo `resources/isdf_diretrizes.json`;
- separar padrões genéricos de padrões específicos da CAIXA;
- criar exemplos validados manualmente para calibração;
- registrar falsos positivos e falsos negativos;
- evitar que regras simples de regex sejam tratadas como interpretação semântica completa;
- manter os resultados gerados fora do Git quando forem produtos de execução;

- versionar diretrizes, glossários e código usados em cada processamento.

14. Síntese

A principal lição aprendida é que o NRPP deve ser entendido como um instrumento de preparação, não de decisão.

Sua contribuição está em transformar normativos extensos em evidências estruturadas, rastreáveis e organizadas segundo uma matriz funcional inspirada na ISDF.

Com a nova perspectiva, o pipeline passa a apoiar uma pergunta arquivística mais qualificada:

que funções institucionais explicam a produção, uso e manutenção dos documentos mencionados ou implicados nos normativos?

Essa pergunta é mais robusta do que a simples identificação de documentos, porque conecta o registro ao contexto funcional que lhe confere significado arquivístico.